

Aula 2 — Estruturação de dados tabulares e relacionais

Da tabela chapada às chaves e relações em Darwin Core Archive

Propósito

Esta aula mostra como passamos de uma tabela em que as informações aparecem repetidas para uma estrutura em que diferentes entidades podem ser organizadas separadamente e relacionadas entre si. Partiremos de tabelas biológicas, construiremos um modelo de biblioteca para compreender identidade, chaves e relações e, em seguida, transferiremos esse raciocínio para dados de biodiversidade e para a estrutura real de um Darwin Core Archive.

Pergunta central — Por que separar informações em diferentes tabelas pode tornar os dados mais consistentes sem perder as relações que existem entre eles?

Resposta-síntese — Em uma tabela chapada, a repetição pode facilitar a leitura e a análise, mas também pode fazer com que informações sobre a mesma entidade sejam armazenadas muitas vezes. Em uma estrutura relacional, entidades que possuem identidade própria podem ser organizadas separadamente e conectadas por identificadores e chaves. Assim, reduzimos repetições desnecessárias e preservamos as relações entre os dados.

A trilha desta aula

1. Tabela chapada e tidy	Observar o que cada linha representa, quais valores se repetem e como variável, observação e unidade observacional ajudam a ler a tabela.
2. Entidades e identidade	Reconhecer o que permanece sendo a mesma coisa. Biblioteca: Machado de Assis pode aparecer em vários livros, mas continua sendo o mesmo autor. Exemplo biológico: o mesmo indivíduo de <i>Paubrasilia echinata</i> pode aparecer no plantio, na medição e na coleta de material; registros diferentes podem estar relacionados ao mesmo organismo.
3. Separar sem perder as relações	Organizar livros, autores, pessoas e empréstimos em tabelas próprias, mantendo cada entidade identificável e conectada às demais.
4. Identificar e relacionar	Usar identificadores, chaves primárias e chaves estrangeiras para preservar identidade e ligação entre tabelas.
5. Interpretar a cardinalidade	Reconhecer relações 1:1, 1:N e N:N e quando uma tabela associativa é necessária.
6. Reconstruir a informação	Usar JOINS para reunir informações relacionadas sem apagar as tabelas originais.
7. Transferir para dados de biodiversidade	Reconhecer a mesma lógica em dados biológicos e, ao final, no Core, nas extensões e no meta.xml de um DwC-A real.

Objetivos

- Reconhecer o que linhas, colunas, variáveis e observações representam em uma tabela e distinguir tabela chapada e dados tidy.
- Reconhecer entidades, atributos e identidade, distinguindo a repetição de uma mesma entidade da existência de entidades diferentes.
- Explicar vantagens e limitações de uma tabela chapada para análise e armazenamento.
- Identificar e validar chaves primárias, chaves estrangeiras e integridade referencial.
- Interpretar cardinalidades 1:1, 1:N e N:N e reconhecer o papel de uma tabela associativa.
- Compreender como JOINS reconstroem informações relacionadas sem substituir as tabelas originais.
- Transferir esse raciocínio para dados de biodiversidade, interpretando Core, extensões, meta.xml, id e coreid em um Darwin Core Archive real.

Percurso da aula

Tabela 1. Percurso da aula — Horário, Tema, Conteúdo principal.

Horário	Tema	Conteúdo principal
08:00–08:40	Tabela chapada: unidade da linha e repetição	Linhas, colunas, unidade da linha; vantagens e limites da repetição em tabelas biológicas.
08:40–09:30	Prática 2.1 — reconhecer unidades em produtos do GBIF	GBIF Simple e lista taxonômica: o que cada linha representa, diferenças de granularidade e repetições observadas.
09:30–09:50	Intervalo	—
09:50–10:40	Tidy data, entidades e identidade: da unidade observacional ao modelo	Variável, observação e unidade observacional; depois, livros, autores, pessoas e empréstimos como unidades com identidade no modelo relacional.
10:40–11:20	Identificar e relacionar: PK, FK e integridade referencial	Identidade das linhas, referências entre tabelas, unicidade e chaves órfãs.
11:20–12:00	Cardinalidades e tabela associativa	Relações 1:1, 1:N e N:N e representação de muitos-para-muitos.
12:00–14:00	Intervalo para almoço	—
14:00–14:50	Reconstruir informações relacionadas	JOINS na biblioteca; tabelas originais × visão combinada; armazenamento relacional × tabela chapada.

Horário	Tema	Conteúdo principal
14:50–15:30	Transferência para dados de biodiversidade	Entidades, identificadores e relações em exemplos biológicos; correspondências e limites da analogia com a biblioteca.
15:30–15:50	Intervalo	—
15:50–16:50	Do modelo relacional ao DwC-A real	Core, extensões, meta.xml, rowType, id, coreid e relações entre arquivos.
16:50–17:30	Prática 2.2 — rastrear relações no DwC-A	Rastreamento de gbifID, Core–extensões, integridade das ligações e relação 1:N com Multimedia.
17:30–18:00	Síntese e fechamento	Retomada da trilha: unidade da linha → identidade → chaves → cardinalidade → JOIN → DwC-A; transição para a Aula 3_4.

1. Tabelas chapadas em dados biológicos

Uma tabela chapada reúne em uma única estrutura as variáveis necessárias para leitura ou análise. Cada linha costuma representar uma unidade analítica — por exemplo, uma ocorrência — e as colunas incorporam informações sobre coleta, localidade, taxonomia, instituição e qualidade.

Tabela 2. Tabelas chapadas em dados biológicos — Bloco conceitual, Exemplos de colunas no GBIF Simple.

Bloco conceitual	Exemplos de colunas no GBIF Simple
Record-level	basisOfRecord, institutionCode, collectionCode, license
Occurrence	occurrenceID, occurrenceStatus, individualCount, recordedBy, catalogNumber, recordNumber
Event	eventDate, day, month, year
Location	countryCode, locality, decimalLatitude, decimalLongitude
Identification	identifiedBy, dateIdentified, typeStatus
Taxon	scientificName, family, genus, species, taxonRank
GBIF — proveniência, interpretação e qualidade	gbifID, datasetKey, taxonKey, lastInterpreted, mediaType, issue

1.1 Vantagens

- Leitura direta: uma linha contém grande parte do contexto necessário.
- É conveniente para filtros, gráficos, mapas e muitas análises estatísticas.
- CSV/TSV é amplamente suportado e pode ser lido por R, planilhas e bancos de dados.
- Evita joins para tarefas exploratórias simples.

1.2 Limitações

- Valores de táxon, dataset, localidade ou instituição se repetem em muitas linhas.
- Uma correção pode precisar ser aplicada em várias células.
- Relações 1:N são achatadas, resumidas ou duplicam a linha central.
- Células vazias podem significar não informado, não aplicável ou não publicado — situações diferentes.
- Misturar identificadores e descrições favorece inconsistências de digitação e atualização.

Importante — Chapada não significa errada. Ela é uma forma adequada para muitas análises. O problema surge quando se espera que uma única tabela preserve todas as relações, históricos e entidades sem redundância.

Integração com o Explorador — O percurso está dividido em A2-E1 (chapada e tidy), A2-E2 (PK, FK, cardinalidade e JOIN) e A2-E3 (core, extensão e meta.xml). Cada prática indica claramente onde começa, o que deve ser feito, qual resultado é esperado e onde termina. Todas as linhas e colunas incorporadas continuam disponíveis.

1.3 Prática guiada em sala 2.1 — interpretar tabelas chapadas do GBIF

1.3.1 Primeiro exemplo — GBIF Simple

Nesta prática, vamos observar uma tabela real do GBIF Simple para reconhecer duas características importantes de uma tabela chapada: uma mesma linha reúne informações de diferentes blocos conceituais e determinados valores podem se repetir em muitos registros.

Arquivo: [data/gbif/simple/gbif_simple.tsv](#). O arquivo completo contém 1.423 registros de espécimes preservados. No Explorador, a visualização da prática apresenta apenas os campos selecionados na Tabela 2, organizados na mesma sequência dos blocos conceituais.

No Explorador, as cores distinguem Record-level, Occurrence, Event, Location, Identification, Taxon e GBIF — proveniência, interpretação e qualidade. Todos permanecem reunidos na mesma tabela, mas descrevem aspectos diferentes do registro biológico.

Como ler a tabela — a cor da coluna indica o bloco conceitual ao qual o campo pertence. A repetição deve ser percebida pela comparação entre os registros, sem ser tratada automaticamente como erro.

O que observar — Cada linha representa uma ocorrência. Instituição, localidade e classificação taxonômica podem se repetir. Observe também issue: no conjunto utilizado, diferentes sinalizações de qualidade aparecem na mesma célula, separadas por ponto e vírgula.

Essa observação será retomada em 2.2, ao discutirmos variável, observação e unidade observacional, e prepara a passagem posterior para entidades, identidade e relações.

ABRIR O EXPLORADOR — [Explorador da Aula 2 — 1.3.1 Primeiro exemplo — GBIF Simple](#).

1.3.2 Segundo exemplo — lista taxonômica agregada do GBIF

No segundo exemplo, a unidade da linha muda. Em `lista_gbif.tsv`, cada linha representa um táxon resultante da agregação, e não uma ocorrência. A tabela possui 700 linhas e 22 colunas; `numberOfOccurrences` informa quantas ocorrências do download foram associadas a cada táxon.

No Explorador, as cores distinguem os blocos conceituais das colunas. Observe especialmente a repetição da classificação superior — reino, filo, classe, ordem e família — e das respectivas chaves utilizadas pelo GBIF.

O que observar — Aqui a unidade da linha mudou: cada linha representa um táxon resultante da agregação. Diferentes táxons podem compartilhar reino, filo, classe, ordem, família e as respectivas chaves; `numberOfOccurrences` é uma contagem associada ao táxon representado naquela linha.

Compare este resultado com o GBIF Simple: nos dois casos temos uma tabela chapada, mas a unidade representada por cada linha é diferente. No GBIF Simple, a linha representa uma ocorrência; na lista agregada, a linha representa um táxon.

Resumo dos blocos conceituais da lista taxonômica agregada

Bloco conceitual	Campos destacados no Explorador
Taxon	scientificName, taxonRank, taxonomicStatus, kingdom, phylum, class, order, family, genus, species
GBIF — interpretação taxonômica	taxonKey, acceptedTaxonKey, acceptedScientificName, kingdomKey, phylumKey, classKey, orderKey, familyKey, genusKey, speciesKey
GBIF — agregação	numberOfOccurrences
GBIF — enriquecimento	iucnRedListCategory

A repetição é particularmente visível na classificação superior e nas chaves correspondentes. Ainda assim, repetição de valor e identidade não são sinônimos: taxonRank = SPECIES, por exemplo, pode repetir-se em muitas linhas sem indicar que todas representam o mesmo táxon.

Proveniência — esta tabela usa o CSV do download 0008869-260721160103020. Preserve a página do download e o JSON da API como evidência de proveniência.

ABRIR O EXPLORADOR — [Explorador da Aula 2 — 1.3.2 Segundo exemplo — lista taxonômica agregada do GBIF](#).

2. Tidy data: variável, observação e unidade observacional

Na prática anterior, observamos duas tabelas chapadas do GBIF sem ainda classificá-las formalmente como tidy ou não tidy. No GBIF Simple, cada linha representa uma ocorrência; na lista taxonômica agregada, cada linha representa um táxon resultante da agregação. Também vimos valores que se repetem e campos que descrevem diferentes aspectos do registro. Agora voltamos às mesmas tabelas com uma nova pergunta: como avaliar se linhas, colunas e células estão organizadas de forma coerente com a unidade que queremos representar?

É essa pergunta que o conceito de tidy data ajuda a responder.

Base conceitual — Wickham (2014) — Cada variável ocupa uma coluna; cada observação ocupa uma linha; cada tipo de unidade observacional ocupa uma tabela.

Referência local: [00 Disciplina/referencias/artigos/Wickham 2014 Tidy Data.pdf](#)

2.1 Como reconhecer uma tabela tidy

Na formulação de Wickham (2014), um conjunto tidy organiza cada variável em uma coluna, cada observação em uma linha e cada tipo de unidade observacional em uma tabela. Em consequência, cada célula registra o valor de uma variável para uma observação.

Identificar a unidade observacional começa por perguntar: o que uma linha desta tabela representa? Duas tabelas podem ser igualmente chapadas e, ainda assim, representar unidades diferentes. No GBIF Simple, uma linha representa uma ocorrência; na lista taxonômica agregada, uma linha representa um táxon resultante da agregação.

Ideia central — Tidy data não pergunta se existem valores repetidos. Pergunta o que cada linha representa, o que cada coluna representa e como os valores estão organizados nas células.

2.2 Aplicando tidy data ao GBIF Simple

Voltemos à primeira tabela da prática. No GBIF Simple, cada linha representa uma ocorrência e campos como eventDate, locality, scientificName e institutionCode ocupam colunas próprias. País, instituição, localidade ou classificação taxonômica podem se repetir em diferentes ocorrências; essa repetição introduz redundância, mas não viola, por si só, a organização tidy.

ABRIR O EXPLORADOR — [Explorador da Aula 2 — 2.2 Aplicando tidy data ao GBIF Simple](#) — releia o mesmo conjunto agora identificando unidade observacional, variáveis e conteúdo das células.

O conjunto também mostra por que precisamos olhar além da repetição. No arquivo utilizado, issue reúne diferentes sinalizações produzidas pelo GBIF em uma mesma célula, separadas por ponto e vírgula. Além disso, em alguns registros, campos de agentes como recordedBy e identifiedBy também codificam listas de pessoas em uma única célula. Se a análise precisar tratar cada sinalização ou cada agente como um valor ou observação separado, esses conteúdos precisam ser desdobrados.

Diagnóstico do exemplo — O GBIF Simple segue a lógica tidy em grande parte de sua estrutura, pois a unidade da linha é clara e a maioria das variáveis possui uma coluna própria. Entretanto, não é estritamente tidy para todas as finalidades e todos os campos: campos multivalorados, como issue — e, conforme o registro, listas de agentes — exigem reorganização quando seus elementos individuais são a unidade de interesse.

2.3 Aplicando tidy data à lista taxonômica agregada do GBIF

Na segunda tabela, a unidade observacional mudou. Cada linha representa um táxon resultante da agregação, enquanto as colunas descrevem propriedades desse táxon ou informações produzidas pelo processamento do GBIF. `scientificName` informa o nome científico; `taxonRank`, a categoria taxonômica; `kingdom`, `phylum`, `class`, `order`, `family`, `genus` e `species` registram níveis da classificação; as colunas terminadas em `Key` registram identificadores usados pelo GBIF; `numberOfOccurrences` informa quantas ocorrências foram associadas ao táxon; e `iucnRedListCategory` acrescenta uma informação de enriquecimento quando disponível.

ABRIR O EXPLORADOR — [Explorador da Aula 2 — 2.3 Aplicando tidy data à lista taxonômica agregada do GBIF](#) — releia a lista agregada verificando a unidade da linha, o papel de cada coluna e a repetição legítima da classificação superior.

A repetição de `kingdom`, `family` ou das respectivas chaves entre linhas não constitui, por si só, um problema de tidy data: táxons diferentes podem compartilhar a mesma classificação superior. Da mesma forma, `numberOfOccurrences` não muda a unidade da linha; é uma variável de contagem associada ao táxon representado naquela linha.

Diagnóstico do exemplo — Para a unidade observacional definida nesta tabela, o táxon agregado, a lista taxonômica segue a organização tidy: cada linha representa uma observação dessa unidade, cada coluna representa uma variável e cada célula registra um valor para essa variável.

2.4 Quando uma tabela não é tidy?

O problema não é simplesmente encontrar o mesmo valor em várias linhas. Uma organização deixa de seguir a lógica tidy quando a estrutura já não permite associar claramente variáveis, observações e unidades observacionais. Exemplos comuns incluem:

- a mesma variável distribuída em colunas como species1, species2 e species3;
- uma célula que codifica vários valores que precisam ser analisados separadamente;
- uma linha que reúne mais de uma observação da unidade que deveria representar;
- tipos diferentes de unidades observacionais misturados de modo que já não seja possível dizer claramente o que uma linha representa.

Colunas como photo1, photo2 e photo3, por exemplo, não representam três variáveis conceitualmente distintas: repetem a mesma variável na estrutura. De modo semelhante, várias medições, identificações ou sinalizações concatenadas em uma célula podem esconder valores ou observações que precisariam ser representados separadamente para determinada análise.

2.5 Quando unidades observacionais diferentes exigem tabelas diferentes

O terceiro princípio de tidy data merece atenção: cada tipo de unidade observacional deve formar uma tabela. Isso não significa que toda tabela chapada precise ser dividida. A separação passa a fazer sentido quando precisamos representar tipos diferentes de unidades.

Na biblioteca que veremos a seguir, livros, autores, pessoas e empréstimos representam unidades distintas. Em dados biológicos, também podemos precisar distinguir um organismo, um acontecimento, um material coletado ou outra unidade sobre a qual registramos informações.

Ideia central — Reconhecer a unidade observacional é essencial para decidir como organizar os dados. Quando existem diferentes tipos de unidades observacionais, pode ser necessário representá-las separadamente para preservar com clareza o que cada linha representa. Na próxima seção, partiremos dessa organização das unidades para construir um modelo de dados usando o exemplo de uma biblioteca.

Base conceitual — Elmasri e Navathe — Entidades, chaves, integridade referencial, cardinalidades e normalização complementam a organização tidy.

A obra é referenciada em 00_Disciplina/referencias/LEIA-ME_REFERENCIAS.txt; não há cópia local por restrição de redistribuição.

Síntese da seção 2

Primeiro pergunte — O que uma linha representa? → unidade observacional. O que uma coluna representa? → variável. O que há em cada célula? → o valor dessa variável para a observação. Existem tipos diferentes de unidades? → podem precisar de tabelas próprias. Na próxima seção, acrescentaremos uma nova pergunta: quais dessas unidades precisam manter identidade própria e se relacionar com outras?

3. Do domínio ao modelo: a biblioteca

Um modelo relacional começa pela pergunta: quais entidades precisam de identidade própria? Na biblioteca, livros, autores e pessoas continuam existindo mesmo quando não há empréstimo. O empréstimo registra uma relação datada entre uma pessoa e um livro.

Tabela 3. Do domínio ao modelo: a biblioteca — Tabela, Uma linha representa, Chave, Atributos principais.

Tabela	Uma linha representa	Chave	Atributos principais
livros	Um livro cadastrado	livro_id	titulo, ano_publicacao
autores	Uma pessoa autora	autor_id	nome_autor
pessoas	Uma pessoa usuária	pessoa_id	nome_pessoa, email
emprestimos	Um ato de empréstimo	emprestimo_id	livro_id, pessoa_id, datas
livro_autor	Uma associação livro–autor	livro_id + autor_id	Duas chaves estrangeiras

Granularidade — Decidir o que uma linha representa vem antes de escolher nomes de colunas. Sem granularidade clara, uma chave pode identificar o objeto errado ou misturar eventos distintos.

4. Chave primária

Uma chave primária identifica cada linha dentro de uma tabela. No exemplo didático, os identificadores terminados em `_id` foram criados para serem estáveis, preenchidos e únicos.

Tabela 4. Chave primária — Propriedade, Critério de verificação, Falha típica.

Propriedade	Critério de verificação	Falha típica
Única	O valor deve ocorrer uma única vez.	Duas pessoas com o mesmo <code>pessoa_id</code> .
Não vazia	Todas as linhas devem possuir valor.	Empréstimo sem <code>emprestimo_id</code> .
Estável	O identificador deve permanecer quando a descrição muda.	Usar nome ou e-mail como chave.
Escopo claro	O escopo em que a chave identifica a linha deve estar explícito.	Confundir <code>catalogNumber</code> local com identificador global.

Na tabela `livro_autor`, a combinação `livro_id` + `autor_id` forma uma chave composta: o mesmo livro pode reaparecer com autores diferentes, e o mesmo autor pode reaparecer em livros diferentes, mas o mesmo par não deve ser duplicado.

5. Chave estrangeira e integridade referencial

Uma chave estrangeira guarda, na tabela filha, um valor que deve corresponder a uma chave da tabela pai. Ela não copia toda a descrição; ela aponta para a linha responsável por aquela identidade.

Tabela 5. Chave estrangeira e integridade referencial — Tabela filha/coluna, Tabela pai/coluna, Leitura.

Tabela filha/coluna	Tabela pai/coluna	Leitura
emprestimos.livro_id	livros.livro_id	Identificar o livro associado ao empréstimo.
emprestimos.pessoa_id	personas.pessoa_id	Identificar a pessoa associada ao empréstimo.
livro_autor.livro_id	livros.livro_id	Identificar o livro ao qual a autoria se refere.
livro_autor.autor_id	autores.autor_id	Identificar o autor associado ao livro.

Chave órfã — Se `emprestimos.livro_id = 99` e não existe `livros.livro_id = 99`, a relação não pode ser reconstruída. A linha filha é órfã em relação ao livro.

6. Cardinalidade

Tabela 6. Cardinalidade — Cardinalidade, Exemplo, Implementação.

Cardinalidade	Exemplo	Implementação
1:1	Uma linha processada e sua contraparte verbatim, quando ambas existem uma vez.	Mesma chave, no máximo uma linha em cada lado.
1:N	Uma pessoa pode realizar vários empréstimos.	pessoa_id se repete em emprestimos.
N:N	Um livro pode ter vários autores; um autor pode ter vários livros.	Tabela associativa livro_autor.

7. Explorando o sistema da biblioteca

O Explorador é a prática principal desta seção. Ele mantém as cinco tabelas originais visíveis, destaca as chaves e reconstrói as relações sem exigir R. Os scripts permanecem apenas como material opcional para quem quiser reproduzir as operações em código.

Tabela 7. Explorando o sistema da biblioteca — Ação no Explorador, Evidência a interpretar.

Ação no Explorador	Evidência a interpretar
Selecionar uma pessoa	emprestimos.pessoa_id encontra pessoas.pessoa_id.
Selecionar um livro	emprestimos.livro_id encontra livros.livro_id.
Selecionar um autor	livro_autor resolve a relação N:N entre livros e autores.

7.1 Sequência de raciocínio

1. Visualizar pessoas, empréstimos, livros, livro_autor e autores como tabelas separadas.
2. Selecionar uma pessoa e observar empréstimos.pessoa_id encontrar pessoas.pessoa_id.
3. Selecionar um livro e observar empréstimos.livro_id encontrar livros.livro_id.
4. Selecionar um autor e acompanhar livro_autor resolver a relação N:N.
5. Desmarcar “mostrar somente linhas relacionadas” e distinguir linhas relacionadas das não relacionadas.
6. Comparar as tabelas originais com a visão chapada e observar a multiplicação causada por vários autores.
7. Explicar, com o exemplo selecionado, PK, FK, integridade referencial e cardinalidade.

O que acontece por trás — O Explorador aplica testes de igualdade entre PK e FK, preserva as tabelas originais e mostra a visão resultante. A interface não elimina o raciocínio relacional: torna cada ligação visível.

ABRIR O EXPLORADOR — [Explorador da Aula 2 — PK, FK, cardinalidade e JOIN](#) — selecione pessoas, livros e autores e acompanhe PK, FK e a relação N:N.

8. Relacionar tabelas não significa apagar as tabelas originais

Uma junção cria uma visão combinada para responder a uma pergunta. livros, pessoas e empréstimos continuam sendo as tabelas de origem das informações. A tabela combinada pode ser exportada para análise, mas não precisa substituir o modelo de armazenamento.

Tabela 8. Relacionar tabelas não significa apagar as tabelas originais — Operação, Resultado, Risco se usado como armazenamento único.

Operação	Resultado	Risco se usado como armazenamento único
empréstimos + livros	Acrescenta título e ano ao ato de empréstimo.	Repete descrição do livro.
+ pessoas	Acrescenta nome e e-mail da pessoa.	Mudança de e-mail exigiria várias correções.
+ livro_autor + autores	Uma linha por empréstimo–autor.	Livros com vários autores duplicam o empréstimo.

9. Transferência para dados biológicos

Tabela 9. Transferência para dados biológicos — Biblioteca, Dados de biodiversidade.

Biblioteca	Dados de biodiversidade
Livro com identidade própria	Occurrence, Event, Taxon ou outra instância identificada.
Empréstimo liga pessoa e livro	Occurrence pode ligar evidência, evento, organismo, local e táxon.
livro_id/pessoa_id	occurrenceID, eventID, taxonID, gbifID e outras chaves.
Pessoa com vários empréstimos	Uma ocorrência com zero ou várias mídias/medições/identificações.
Tabela associativa livro_autor	Arquivos de associação ou extensões preservam relações sem colocar listas em uma célula.

Limite da comparação — A biblioteca ajuda a raciocinar sobre identidade e relações. Os nomes e as regras efetivas dos dados biológicos devem ser lidos na especificação e nos metadados do archive, não deduzidos pela analogia.

10. O Darwin Core Archive fornecido

O diretório data/gbif/dwca contém o download GBIF 0000805-260715120105164, publicado em 15/07/2026. Trata-se de um DwC-A com Occurrence Core, formado por 1.423 espécimes preservados de Plantae, usando Catalogue of Life, nos municípios de Arcos, Doresópolis e Pains, Minas Gerais. metadata.xml registra título, data e filtro; meta.xml declara occurrence.txt como core e verbatim.txt e multimedia.txt como extensões.

PK — identifica a linha do core/tabela pai. **FK** — aponta para a PK do core/tabela pai.

Um único parágrafo de filtro é suficiente: o filtro pertence ao download GBIF completo, não a cada dataset constituinte. O professor fornece esse contexto mínimo; o aluno confirma a informação em metadata.xml e usa citations.txt para reconhecer os provedores.

Tabela 10. O Darwin Core Archive fornecido — Arquivo, Papel, Linhas de dados, Ligação.

Arquivo	Papel	Linhas de dados	Ligação
occurrence.txt	Core Occurrence processado	1.423	gbifID em <id index="0">
verbatim.txt	Valores mais próximos do fornecido pelo publicador	1.423	gbifID em <coreid index="0">
multimedia.txt	Extensão GBIF Multimedia	610	gbifID em <coreid index="0">
meta.xml	Descrição estrutural	—	rowType, arquivos, índices e termos
metadata.xml	Identificação e contexto do download	—	ID 0000805-260715120105164; 15/07/2026; espécimes; Plantae/COL; Arcos, Doresópolis e Pains.

As 610 linhas de Multimedia estão ligadas a 590 ocorrências; algumas ocorrências possuem mais de uma mídia e muitas não possuem nenhuma. Esse é um relacionamento 1:N que não precisa duplicar todas as colunas de occurrence.txt.

10.1 id, coreid e termos

Em meta.xml, <id> e <coreid> são elementos estruturais do formato textual DwC-A. Eles indicam posições de colunas, não são propriedades do vocabulário Darwin Core. Os trechos literais abaixo mostram rowType, arquivo, chave e mapeamento do campo.

Evidência 1 — core Occurrence

```
<core ... rowType="http://rs.tdwg.org/dwc/terms/Occurrence">
  <files><location>occurrence.txt</location></files>
  <id index="0" />
  <field index="0" term="http://rs.gbif.org/terms/1.0/gbifID"/>
</core>
```

Interpretação — rowType=Occurrence informa que cada linha de occurrence.txt representa uma Occurrence. <id index="0"/> define a coluna de índice 0 como o identificador do Core usado nas ligações com extensões; <field index="0" ... gbifID> mapeia essa mesma coluna para gbifID. Assim, <id> é estrutural e gbifID é o termo associado ao valor da coluna.

Evidência 2 — extensão verbatim

```
<extension ... rowType="http://rs.tdwg.org/dwc/terms/Occurrence">
  <files><location>verbatim.txt</location></files>
  <coreid index="0" />
  <field index="0" term="http://rs.gbif.org/terms/1.0/gbifID"/>
</extension>
```

Interpretação — rowType=Occurrence informa que cada linha de verbatim.txt representa uma Occurrence. <coreid index="0"/> diz que a coluna de índice 0 contém o identificador do Core ao qual a linha se liga, valor que deve corresponder ao <id>; a mesma coluna é mapeada para gbifID.

Evidência 3 — extensão Multimedia

```
<extension ... rowType="http://rs.gbif.org/terms/1.0/Multimedia">
  <files><location>multimedia.txt</location></files>
  <coreid index="0" />
  <field index="0" term="http://rs.gbif.org/terms/1.0/gbifID"/>
  <field index="3" term="http://purl.org/dc/terms/identifier"/>
</extension>
```

Interpretação — rowType=Multimedia informa que cada linha de multimedia.txt representa um registro de mídia. <coreid index="0"/> liga a linha ao Core pela coluna de índice 0, mapeada para gbifID; <field index="3" ... identifier> mapeia a coluna de índice 3 para dcterms:identifier, identificando o recurso de mídia.

Precisão terminológica — No arquivo, gbifID funciona como chave técnica do core e das extensões. Não é correto transformar coreid no nome de uma coluna obrigatória nem chamá-lo de propriedade dwc:coreid.

10.2 Do meta.xml ao relacionamento entre as tabelas

O meta.xml não contém os dados biológicos: ele descreve como os arquivos tabulares devem ser interpretados em conjunto. No DwC-A do GBIF usado nesta aula, occurrence.txt é o Core e verbatim.txt e multimedia.txt são extensões. A ligação é reconstruída comparando a coluna indicada por <id> no Core com a coluna indicada por <coreid> em cada extensão.

Leitura integrada do meta.xml e dos arquivos tabulares

Aviso de leitura — <id> e <coreid> são mecanismos estruturais do formato DwC-A. Nesta aula, PK e FK são usados apenas como uma analogia relacional didática para compreender a ligação entre as tabelas.

Core da aula — occurrence.txt: <id index="0"> indica a coluna estrutural usada para identificar as linhas do Core.

Extensões da aula — verbatim.txt e multimedia.txt: <coreid index="0"> indica a coluna que referencia a linha correspondente do Core.

Exemplo real — o gbifID 912693816 pode ser rastreado de occurrence.txt para verbatim.txt e multimedia.txt. O gbifID 5294513309 demonstra uma relação 1:N com várias linhas de multimídia.

ABRIR O EXPLORADOR — [Explorador da Aula 2 — meta.xml real](#) — leia o meta.xml real e acompanhe occurrence.txt[id] → verbatim.txt[coreid] e occurrence.txt[id] → multimedia.txt[coreid].

11. Prática guiada em sala 2.2 — rastrear chaves no DwC-A

ABRIR O EXPLORADOR — [Explorador da Aula 2 — Prática guiada 2.2](#) — comece no marcador INÍCIO DA PRÁTICA e acompanhe id/coreid nos arquivos reais.

1. No Explorador, identifique o download: código, data, filtro, core e extensões.
2. No trecho real de meta.xml, localize rowType, location e <id index="0"> do core.
3. Localize <coreid index="0"> nas duas extensões e explique para onde ele aponta.
4. Use a demonstração para validar a PK occurrence.gbifID e verificar se as FKs das extensões possuem chaves órfãs.
5. Rastreie gbifID 912693816 entre occurrence, verbatim e multimedia; compare um valor processado com o correspondente verbatim.
6. Use gbifID 5294513309 para interpretar o máximo de mídias e a cardinalidade core–Multimedia.
7. Explique o que seria perdido ou repetido se multimedia fosse achatada em occurrence.txt.

12. Síntese e retomada dos objetivos

Ao fechar a aula, retome os objetivos: diferenciar tabela chapada e relacional; reconhecer chaves primárias e estrangeiras; interpretar cardinalidade; rastrear relações no sistema da biblioteca e transferir o raciocínio para o DwC-A.

Tabela 11. Síntese e retomada dos objetivos — Pergunta, Resposta curta.

Pergunta	Resposta curta
Por que usar tabela chapada?	Facilita leitura e análise quando uma linha representa claramente a unidade analítica.
Por que separar tabelas?	Reduz redundância e preserva identidades e relações com diferentes cardinalidades.
O que faz a chave primária?	Identifica uma linha dentro de uma tabela.
O que faz a chave estrangeira?	Liga uma linha filha à identidade registrada em outra tabela.
O que é integridade referencial?	Toda chave estrangeira preenchida encontra uma chave válida na tabela referenciada.
Como o DwC-A usa isso?	Um core central e extensões relacionadas pela coluna indicada em id/coreid.

Síntese conceitual — estrutura, chaves e cardinalidade

O objetivo não é decorar símbolos, mas reconhecer o que cada linha representa e como as identidades permitem reconstruir relações sem duplicar descrições.

Tabela chapada, tidy data e modelo relacional: resposta completa

- Vantagens: leitura direta, filtros e análises simples, compatibilidade com R/planilhas e ausência de joins em tarefas exploratórias.
- Limitações: repetição, correções em várias células, ambiguidade de vazios e dificuldade para preservar históricos e relações 1:N.

- Exemplo 1:N: uma ocorrência com várias imagens. No achatamento, a ocorrência é duplicada ou as imagens são resumidas/perdidas.
- Tabela chapada não é errada: é adequada quando a unidade da linha está clara e o objetivo é análise ou intercâmbio simples.

Uma tabela chapada pode ser tidy quando uma linha representa uma unidade claramente definida. Ela deixa de ser tidy quando colunas ou células escondem observações repetidas. Dados relacionais podem manter cada unidade em uma tabela e gerar uma visão chapada por JOIN; armazenamento e resultado analítico não são a mesma coisa.

PK, FK e integridade referencial

- Chave primária identifica uma linha no escopo da tabela e deve ser única, não vazia, estável e documentada.
- Chave estrangeira guarda na tabela filha um valor correspondente à chave da tabela pai; ela aponta, não copia a descrição.
- Chave órfã é uma FK que não encontra a linha referenciada; a relação não pode ser reconstruída.
- Biblioteca: `emprestimos.livro_id` aponta para `livros.livro_id`; `emprestimos.pessoa_id` aponta para `pessoas.pessoa_id`.
- Biodiversidade: em modelo relacional, `Occurrence.eventID` pode apontar para `Event.eventID`; em DwC-A, `meta.xml` declara qual coluna da extensão referencia a chave do core.

Cardinalidades 1:1, 1:N e N:N

- 1:1: uma linha de um lado corresponde a no máximo uma do outro; exemplo: linha processada e sua contraparte verbatim quando existe uma de cada.
- 1:N: uma linha pai corresponde a várias filhas; exemplo: uma pessoa com muitos empréstimos ou uma ocorrência com muitas mídias.
- N:N: várias linhas de ambos os lados podem se relacionar. Não se resolve colocando listas em uma célula ou uma única FK em apenas uma tabela.

- A relação N:N exige tabela associativa. livro_autor contém livro_id e autor_id; o par forma chave composta e cada coluna também é FK.
- Em biodiversidade, occurrence_media pode ligar várias ocorrências a várias mídias quando uma mídia documenta mais de uma ocorrência e cada ocorrência possui várias mídias.
- No DwC-A, extensões apontam estruturalmente para o core; isso não cria uma rede N:N livre entre extensões. Modelos relacionais ou DwC-DP tornam essas associações mais explícitas.

13. Fechamento da Aula 2 — o caminho percorrido

Síntese visual — A Aula 2 termina retomando como a unidade da linha, a identidade e as relações orientam a passagem de uma tabela para uma estrutura relacional e para o DwC-A. Siga os blocos da esquerda para a direita e continue na segunda linha.

1 DEFINIR A UNIDADE DA LINHA Pergunte primeiro o que cada linha representa. Variável, observação e unidade observacional precisam estar claras antes de analisar a estrutura.	2 LER A TABELA CHAPADA Uma tabela chapada pode ser útil e tidy, mas a repetição pode dificultar atualização, histórico e representação de relações complexas.	3 IDENTIFICAR A CHAVE PRIMÁRIA A PK identifica cada linha no escopo da tabela. Unicidade, ausência de vazios, estabilidade e documentação sustentam a identidade.	4 RECONHECER AS LIGAÇÕES A FK referencia a chave da tabela pai. Integridade referencial permite reconstruir a relação e detectar chaves órfãs.
5 INTERPRETAR A CARDINALIDADE 1:1, 1:N e N:N descrevem quantas linhas podem se relacionar entre os lados e determinam como a estrutura deve ser organizada.	6 RECONSTRUIR COM TABELA ASSOCIATIVA E JOIN Relações N:N usam tabela associativa; JOIN reúne informações sem apagar as tabelas originais nem transformar a relação em lista dentro de uma célula.	7 RASTREAR O DW-C-A No DwC-A, o Core, as extensões e o meta.xml declaram a estrutura. id e coreid permitem rastrear linhas entre arquivos relacionados.	→ PRÓXIMO PASSO: AULA 3_4 Depois de compreender tabelas, identidade e ligações, passaremos a interpretar classes, propriedades, valores e relações do Darwin Core.

Em uma frase — Na Aula 2, aprendemos a reconhecer o que cada linha representa e a reconstruir relações por meio de chaves e cardinalidades antes de avançar para a semântica do Darwin Core.

14. Atividade Aula 2 — revisão dos conceitos da aula

Objetivo — revisar, de forma objetiva, conceitos centrais trabalhados na Aula 2: vocabulário relacional básico, chaves primárias e estrangeiras, integridade referencial, cardinalidades, tabela associativa e tidy data.

Material recebido — o arquivo [atividade/Atividade Aula 2.docx](#). A atividade possui cinco questões, cada uma valendo 3 pontos, totalizando 15 pontos.

A atividade é independente do Explorador e não exige interpretação de Darwin Core Archive. As questões retomam diretamente os exemplos e definições apresentados na Aula 2.

Conteúdo avaliado — vocabulário relacional básico; identificação de PK e FK; cardinalidades; integridade referencial e chave órfã; tabela associativa; definição de tidy data e aplicação do conceito em um exemplo biológico.

Produto a entregar — o DOCX individual preenchido e renomeado como “Atividade Aula 2 - Nome Sobrenome.docx”, enviado como anexo para pablopains@yahoo.com.br.

Arquivo: [atividade/Atividade Aula 2.docx](#). Valor: 15 pontos (5 questões × 3 pontos).

15. Preparação para a Aula 3_4

A Aula 3_4 avançará da estrutura para a semântica: classes, propriedades, valores, namespaces, escolha do core, achatamento e diferenças entre DwC-A e DwC-DP. Chegue sabendo responder o que uma linha representa e como uma chave liga dois arquivos.